

# 神经元和感知机

高 阳，李文斌

<http://cs.nju.edu.cn/rl>

2023年11月07日

# 大纲

脑和神经元


感知机学习

线性可分性

# 生物学基础


树突：输入

轴突：输出



- ✓ 神经元内化学物质调节内部电位
- ✓ 跨膜电位达到一个阈值时，则激活或放电
- ✓ (固定)时间和强度的脉冲传递给轴突
- ✓ 轴突像树枝状，连接到突触

# 生物学基础



- ✓ 分布/并行计算模型
- ✓ 调整节点间的连接关系

## □ 人脑

- ✓  $10^{11}$ 个神经元 (100 billion)
- ✓ 每个神经元处理速度为 $10^{-3}s$
- ✓ 识别人脸, 需要约100个神经元计算

# 赫布理论Hebbian Theory

□ 唐纳德·赫布（1904-1985）于1949年提出

- 加拿大生理心理学家
- 连接强度调整量与输入输出的乘积成正比，显然经常出现的模式将增强神经元之间的连接
- 与巴普洛夫的‘条件反射’一致
- 又称为“长程增强机制” (LTP, Long Term Potentiation) 或“神经可塑” (Neural Plasticity)

# 早期发展历史

- ❑ 1943年，心理学家W. McCulloch和数理逻辑学家W. Pitts首次提出神经元的数学模型MP模型
- ❑ 1948年，冯·诺依曼提出相互再生自动机网络结构
- ❑ 1950s，F. Rosenblatt提出感知机模型
- ❑ 1960s，Widrow提出非线性多层自适应网络
- ❑ 1969年，Minsky出版《感知机》一书
- ❑ 1982年和1984年，物理学家Hopfield在美国科学院院刊上发表ANN文章
- ❑ 2006年，Hinton发表深度信念网络→深度学习


。 。 。

# MP神经元基本结构

□ 输入  $X = [x_1, x_2, x_3, \dots]$

□ 权值  $W = [w_1, w_2, w_3, \dots]$

□ 激活函数  $f(net) = f(\sum(w_i * x_i))$





# MP神经元基本结构

□ 输入  $X = [x_1, x_2, x_3, \dots]$

□ 权值  $W = [w_1, w_2, w_3, \dots]$

□ 激活函数  $f(net) = f(\sum(w_i * x_i))$

□ 偏置单元 (bias unit)  $x_0$ , 其对应权值为  $w_0$





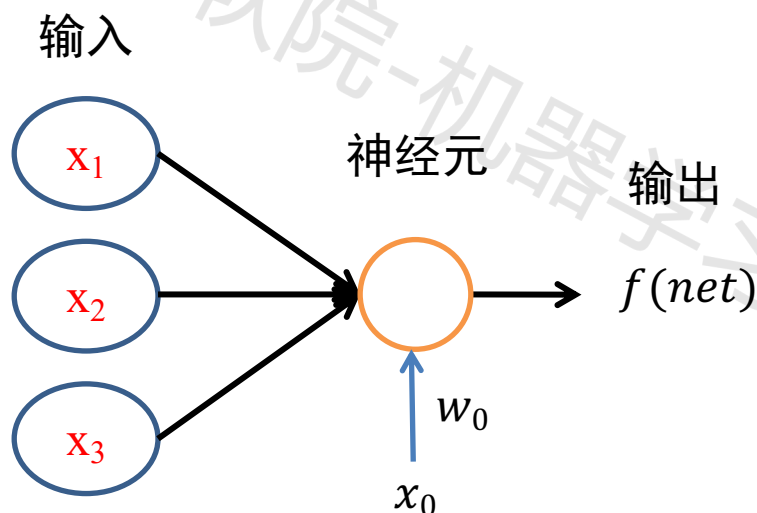

# MP神经元基本结构

□ 输入  $X = [x_1, x_2, x_3, \dots]$

□ 权值  $W = [w_1, w_2, w_3, \dots]$

□ 激活函数  $f(net) = f(\sum(w_i * x_i))$

□ 偏置单元 (bias unit)  $x_0$ , 其对应权值为  $w_0$




- ✓ 一组输入加权  $w_i$  相当于突触
- ✓ 一个加法器把输入信号相加 (与收集电荷的细胞膜等价)
- ✓ 一个激活函数 (最初是一个阈值函数) 决定细胞对于当前的输入是否激活 (“放电”)


# MP神经元模型

$$h = \sum_{i=1}^m w_i x_i$$

$$o = g(h) = \begin{cases} 1, & \text{if } h > 0 \\ 0, & \text{if } h \leq 0 \end{cases}$$



逻辑与的神经元模型  
(阈值为0, 大于等于0输出1)




逻辑或的神经元模型  
(阈值为0, 小于0输出0)

# MP神经元的局限

- 输入方面：线性求和 → 非线性求和
- 输出方面：单一输出值 → 脉冲序列
- 更新机制：时钟同步更新 → 随机异步更新
- 权值的物理（生理）意义
  - ✓ 两类神经元连接（兴奋性连接，权值为正；抑制性连接，权值为负）
  - ✓ 但不存在由正到负、或者由负到正的连接

# 激活函数




单位阶跃函数

Heaviside step function

$$f(x) := \begin{cases} 1, & \text{if } x \geq 0 \\ 0, & \text{if } x < 0 \end{cases}$$

- 不连续函数
- 对变化敏感
- $x = 0$ , 不可微
- 一般适合单层感知机




Sigmoid function

$$f(x) := \frac{1}{1 + e^{-x}}$$

- 连续、光滑、严格单调
- 函数范围在(0,1)之间
- S形曲线, 非线性函数
- 导数为其本身的函数


# 激活函数



Sigmoid function

$$f(x) := \frac{1}{1 + e^{-x}}$$

- 连续、光滑、严格单调
- 函数范围在(0,1)之间
- S形曲线，非线性函数
- 导数为其本身的函数




导数:

$$f'(x) = f(x)(1 - f(x))$$

- 饱和型激励函数
- 导数始终小于1，在0周围变化
- 容易造成梯度消失问题
- 不以0为对称轴
- 指数计算代价大


# 激活函数

- 饱和激活函数：Sigmoid, tanh, ...
- 非饱和激活函数：ReLU, ELU, Leaky ReLU, PReLU, RReLU, ...




$$f(x) := \max(0, x)$$

$$f'(x) := \begin{cases} 1, & \text{if } x > 0 \\ 0, & \text{if } x < 0 \end{cases}$$



$$f(x) := \begin{cases} x, & \text{if } x \geq 0 \\ a \cdot x, & \text{if } x < 0 \end{cases}$$

$$f'(x) := \begin{cases} 1, & \text{if } x \geq 0 \\ a, & \text{if } x < 0 \end{cases}$$




$$f(a, x) := \begin{cases} x, & \text{if } x \geq 0 \\ a \cdot x, & \text{if } x < 0 \end{cases}$$


训练阶段 a 从一个均匀分布中随机采样

# 生物神经元→计算神经元

生物神经元



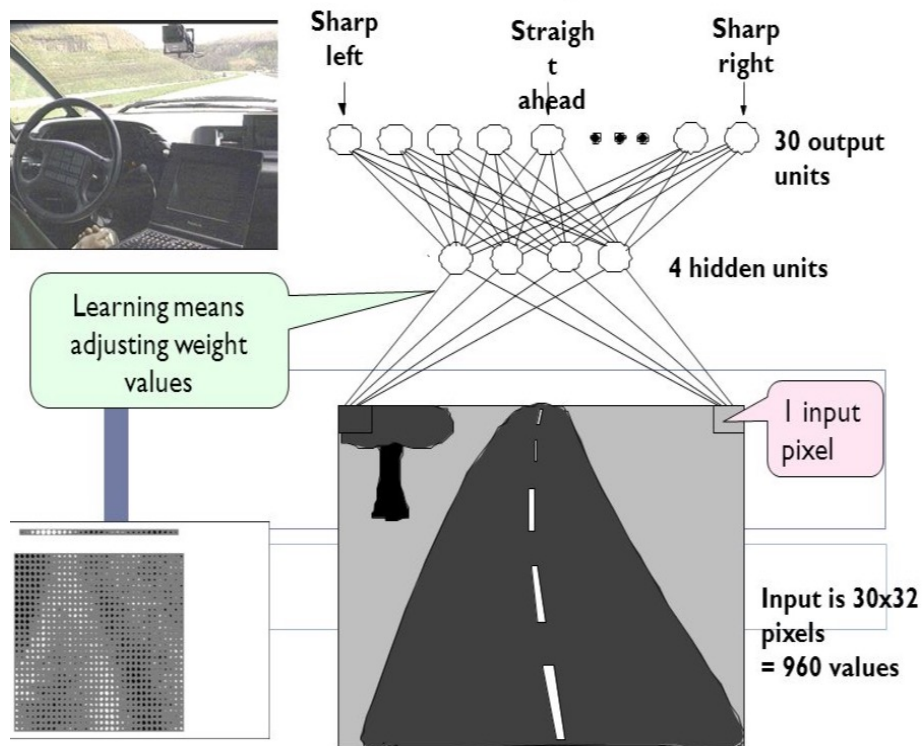
计算神经元



# 神经元→神经网络表示

□ ALVINN : **A**utonomous **L**and **V**ehicle **I**n a **N**eural **N**etwork

## Neural Net example: ALVINN



□ 1989年, CMU研发

□ 输入: 30\*32的像素

□ 4个隐藏节点

□ 输出: 30个驾驶动作(急剧左转、急剧右转, 正前方行进.....)

有向/无向? 有环/无环? 结构?



# 大纲

脑和神经元

感知机学习

线性可分性

# 感知机和感知机学习

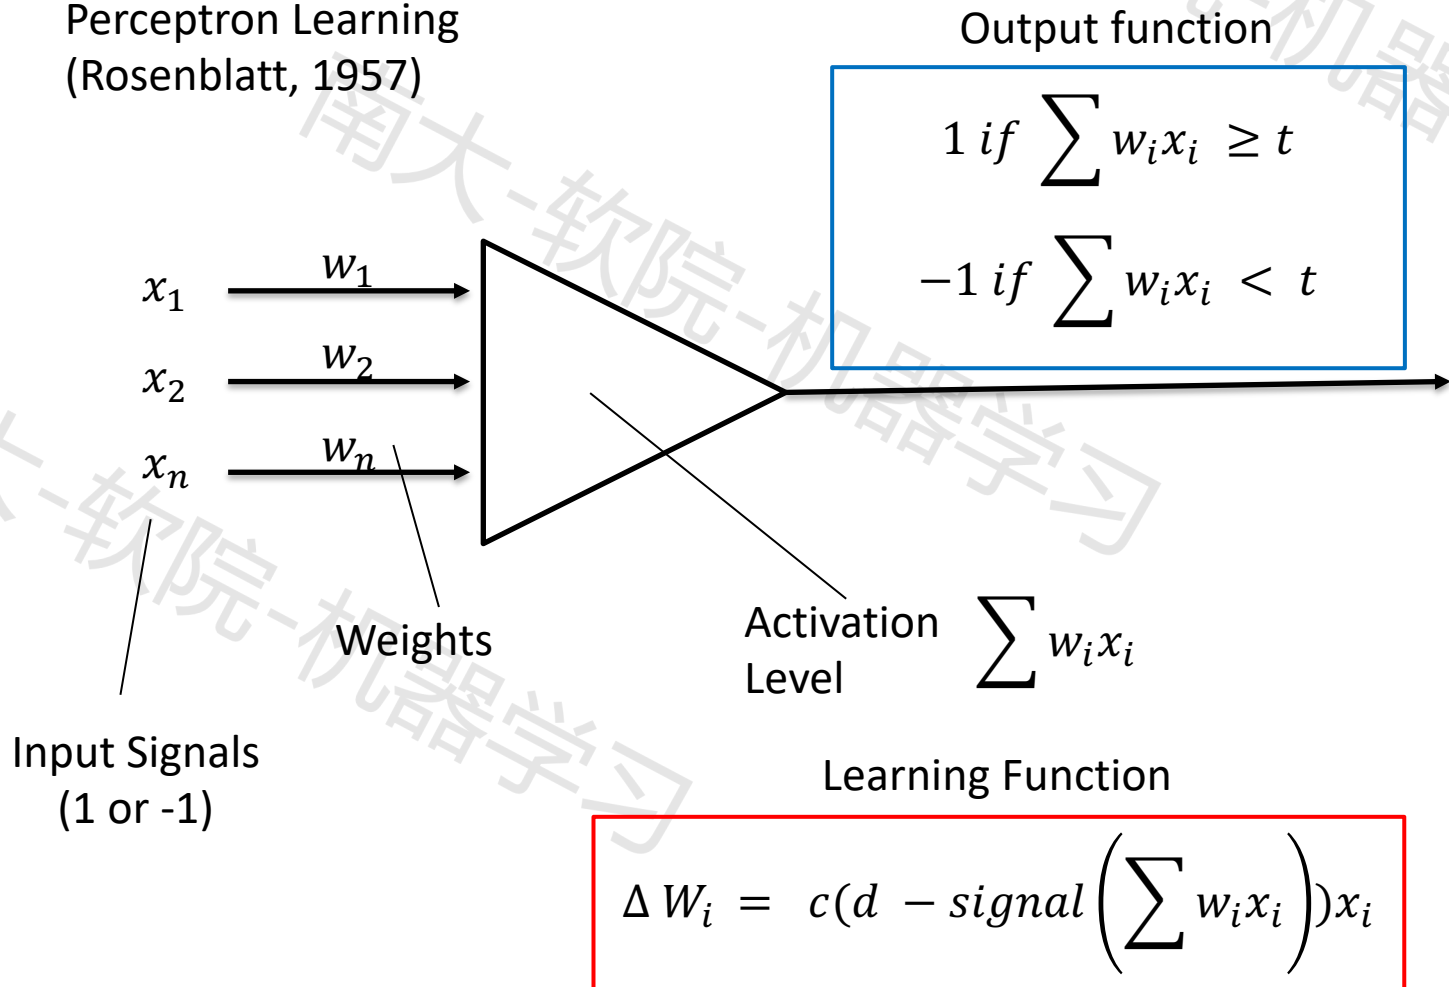
□ Frank Rosenblatt, 1957年, Cornell 航空实验室 (Cornell Aeronautical Laboratory)

□ 最简单形式的前馈式人工神经网络

□ 一种二元线性分类器, 使用特征向量作为输入, 把矩阵上的输入 $x$  (实数值向量) 映射到输出值 $f(x)$ 上 (一个二元的值)


# 感知机结构

Perceptron Learning  
(Rosenblatt, 1957)



# 感知机结构

## □ 非线性前馈网络



- 同层内无互连
- 不同层间无反馈
- 由下层向上层传递
- 输入输出均为离散值
- 由阈值函数决定其输出

# 有监督的学习机制

□  $c$ 是常数，表示学习率

教材上符号表达

□  $d$ 是期望的输出，取值为1或-1

$$w_{ij} \leftarrow w_{ij} - \eta(y_j - t_j) \cdot x_i$$

□  $\text{sign}$ 是感知机的输出，取值为1或-1

$$\Delta W_i = c(d - \text{sign}(\sum w_i * x_i)) X_i$$

□ 期望输出和实际输出相同，不改变权值

□ 实际输出为-1，期望输出为+1，则增加 $2cX_i$


□ 实际输出为+1，期望输出为-1，则减少 $2cX_i$

# 感知机的学习算法

1. 权值初始化
2. 输入样本对
3. 计算输出
4. 根据感知机学习规则调整权重
5. 返回步骤2，输入下一对样本，直至对所有样本的实际输出与期望输出相等

# 例子

$x_1$	$x_2$	Output
1.0	1.0	1
9.4	6.4	-1
2.5	2.1	1
8.0	7.7	-1
0.5	2.2	1
7.9	8.4	-1
7.0	7.0	-1
2.8	0.8	1
1.2	3.0	1
7.8	6.1	-1



# 例子

$x_1$	$x_2$	Output
1.0	1.0	1
9.4	6.4	-1
2.5	2.1	1
8.0	7.7	-1
0.5	2.2	1
7.9	8.4	-1
7.0	7.0	-1
2.8	0.8	1
1.2	3.0	1
7.8	6.1	-1

$$f(net) = f(w_0 * x_0 + w_1 * x_1 + w_2 * x_2)$$

$x_0$ 是偏置单元，通常取1

- 假设初始权值为 $[-0.6, 0.75, 0.5]$
- 对第一行数据来说
$$f_1 = f(-0.6 * 1 + 0.75 * 1 + 0.5 * 1)$$
$$= f(0.65) = 1$$
- 与期望值一样，所以 $W$ 向量不变， $W_1 = W_0$



$x_1$	$x_2$	Output
1.0	1.0	1
9.4	6.4	-1
2.5	2.1	1
8.0	7.7	-1
0.5	2.2	1
7.9	8.4	-1
7.0	7.0	-1
2.8	0.8	1
1.2	3.0	1
7.8	6.1	-1

$$f(net) = f(w_0 * x_0 + w_1 * x_1 + w_2 * x_2)$$

$x_0$ 是偏置单元，通常取1

- 假设初始权值为 $[-0.6, 0.75, 0.5]$
- 对第一行数据来说
 
$$f_1 = f(-0.6 * 1 + 0.75 * 1 + 0.5 * 1) = f(0.65) = 1$$
- 与期望值一样，所以 $W$ 向量不变， $W_1 = W_0$



- $$f_2 = f(-0.6 * 1 + 0.75 * 9.4 + 0.5 * 6.4) = f(9.65) = 1$$
- 期望为-1，所以 $W_2 = W_1 + 0.2 * (-2)X_2$ 

$$W_2 = [-0.6, 0.75, 0.5] - 0.4 * [1, 9.4, 6.4]$$

$$= [-1.00, -3.01, -2.06]$$

$x_1$	$x_2$	Output
1.0	1.0	1
9.4	6.4	-1
2.5	2.1	1
8.0	7.7	-1
0.5	2.2	1
7.9	8.4	-1
7.0	7.0	-1
2.8	0.8	1
1.2	3.0	1
7.8	6.1	-1

$x_0$ 固定为1  
a固定为0.2

$$f(net) = f(w_0 * x_0 + w_1 * x_1 + w_2 * x_2)$$

$x_0$ 是偏置单元，通常取1

- 假设初始权值为 $[-0.6, 0.75, 0.5]$
- 对第一行数据来说  

$$f_1 = f(-0.6 * 1 + 0.75 * 1 + 0.5 * 1) = f(0.65) = 1$$
- 与期望值一样，所以 $W$ 向量不变， $W_1 = W_0$

$$f_2 = f(-0.6 * 1 + 0.75 * 9.4 + 0.5 * 6.4) = f(9.65) = 1$$

- 期望为-1，所以 $W_2 = W_1 + 0.2 * (-2)X_2$   

$$W_2 = [-0.6, 0.75, 0.5] - 0.4 * [1, 9.4, 6.4]$$

$$= [-1.00, -3.01, -2.06]$$

$$f_3 = f(-1 * 1 - 3.01 * 2.5 - 2.06 * 2.1)$$


$$= f(-12.84) = -1$$

$$W_3 = W_2 + 0.2 * 2 * X_3 = [-0.60, -2.01, -1.22]$$


.....

- 最终结果为 $W=[10.9, -1.3, -1.1]$


# 图示




# 图示



# 图示



# 图示



# 大纲


脑和神经元

感知机学习

线性可分性


# OR函数

IN <sub>1</sub>	IN <sub>2</sub>	t
0	0	0
0	1	1
1	0	1
1	1	1



$$w_{ij} \leftarrow w_{ij} - \eta(y_j - t_j) \cdot x_i$$

例题中，令  $\eta = 0.25$



$$w_0 = -0.05,$$

$$w_1 = -0.02,$$

$$w_2 = 0.27,$$

课堂练习



$$w_0 = ?$$

$$w_1 = ?$$

$$w_2 = ?$$



# 决策边界

## □ 决策边界 Decision boundary

- ✓ 鉴别函数 discriminant function

$$\mathbf{w}^T \cdot \mathbf{x} \geq 0$$

- ✓ 神经元激活(假设激活函数是阈值为0的阶跃函数)

- ✓ 等价于向量内积

$$\mathbf{a} \cdot \mathbf{b} = \|\mathbf{a}\| \|\mathbf{b}\| \cos \theta$$


- ✓ 假设有两个输入点

$$\left. \begin{array}{l} \mathbf{w}^T \cdot \mathbf{x}_1 = 1 \\ \mathbf{w}^T \cdot \mathbf{x}_2 = 1 \end{array} \right\} \mathbf{w}^T \cdot (\mathbf{x}_1 - \mathbf{x}_2) = 0$$

□ 物理解释:

$\mathbf{w}^T$  就是找与  $\mathbf{x}_1$   $\mathbf{x}_2$  连线的垂直线

# 多分类的决策边界



- 每一个输出神经元定义一条决策边界
- 多个神经元就决定了多分类的决策边界

# 感知机收敛理论

- [Rosenblatt, 1962] 给定一个线性可分数据集，感知机将在有限次迭代中收敛到一个决策边界
- 定义 $\gamma$ 是分离超平面与最接近的数据点之间的距离，则迭代次数的界是 $1/\gamma^2$

# 感知机收敛理论

□ [Rosenblatt, 1962] 给定一个线性可分数据集，感知机将在有限次迭代中收敛到一个决策边界

□ 定义 $\gamma$ 是分离超平面与最接近的数据点之间的距离，则迭代次数的界是 $1/\gamma^2$

$$\begin{aligned}\mathbf{w}^* \cdot \mathbf{w}^{(t)} &= \mathbf{w}^* \cdot (\mathbf{w}^{(t-1)} + y\mathbf{x}) \\ &= \mathbf{w}^* \cdot \mathbf{w}^{(t-1)} + y\mathbf{w}^* \cdot \mathbf{x} \\ &\geq \mathbf{w}^* \cdot \mathbf{w}^{(t-1)} + \gamma \geq t\gamma\end{aligned}$$

□ 证明思路：


考察权重向量的迭代过程，假设第 $t$ 轮输出有误差，需要更改 $t-1$ 轮的权值

结论1：每次权值更新至少比上一轮增加 $\gamma$

# 感知机收敛理论

□ 柯西不等式(Cauchy-Schwartz inequality)

$$t\gamma \leq \mathbf{w}^* \cdot \mathbf{w}^{(t)} \leq \|\mathbf{w}^*\| \|\mathbf{w}^{(t)}\|$$



$$t\gamma \leq \|\mathbf{w}^{(t)}\|$$

$$\|\mathbf{w}^{(t)}\|^2 = \|\mathbf{w}^{(t-1)} + y\mathbf{x}\|^2$$

$$= \|\mathbf{w}^{(t-1)}\|^2 + y^2 \|\mathbf{x}\|^2 + 2y\mathbf{w}^{(t-1)} \cdot \mathbf{x}$$

$$\leq \|\mathbf{w}^{(t-1)}\|^2 + 1 \leq t$$


根据假设



假设上一轮输出不正确, 此项为0.

思考: 神经网络的输入输出

$$t\gamma \leq \|\mathbf{w}^{(t-1)}\| \leq \sqrt{t}$$



$$t \leq 1/\gamma^2$$


# 感知机学习缺点

- 感知机属于单层神经网络，不能解决一类非线性可分的问题
- 典型的例子就是异或

表 1. 异或真值表

输入1	输入2	输出
0	0	0
0	1	1
1	0	1
1	1	0


图 1. 异或问题



➤ 在二维空间中没有可分离点集  $\{(0,0),(1,1)\}$  和  $\{(0,1),(1,0)\}$  的直线

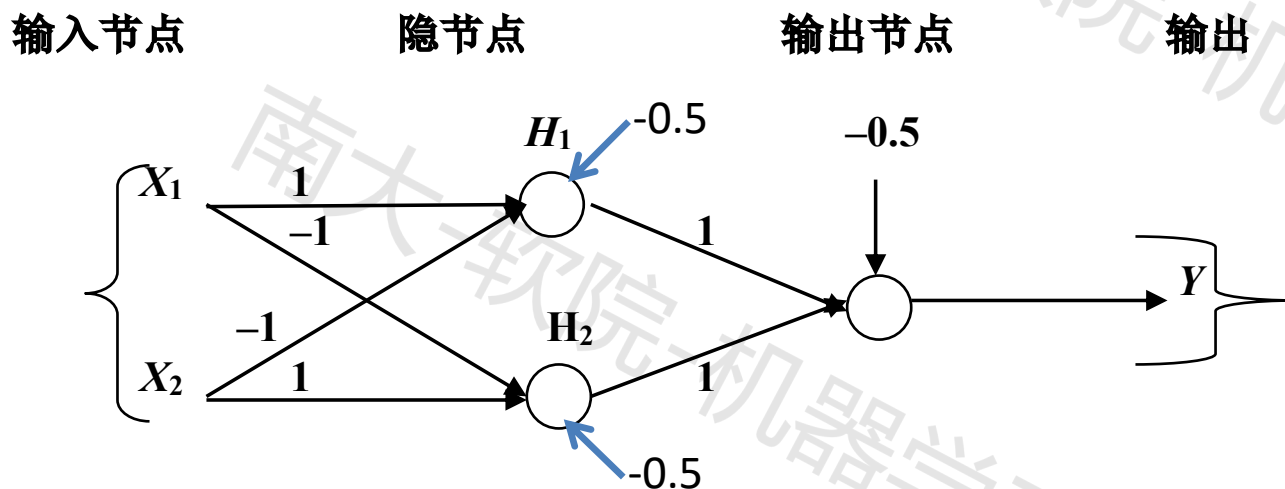
# 用线性分类器处理异或

In <sub>1</sub>	In <sub>2</sub>	In <sub>3</sub>	Output
0	0	1	1
0	1	0	0
1	0	0	0
1	1	0	1



利用核技巧(SVM一讲介绍)，将数据投影到合适的高维空间

# 用多层网络处理异或



□ 权重向量(1,-1)、(-1,1)

输入		隐节点输出		输出节点	$X_1 \text{ XOR } X_2$
$X_1$	$X_2$	$H_1$	$H_2$		
0	0	0	0	$-0.5 \rightarrow 0$	0
0	1	$-1 \rightarrow 0$	1	$0.5 \rightarrow 1$	1
1	0	1	$-1 \rightarrow 0$	$0.5 \rightarrow 1$	1
1	1	0	0	$-0.5 \rightarrow 0$	0



# 感知机的表达能力

WHY?



□ 感知机是n维实例空间的超平面决策

□ 候选假设空间H(决策变量的集合): 所有可能实数权向量的集合

$$H = \{\vec{W} | \vec{W} \in R^{(n+1)}\}$$

□ 广义布尔函数 m-of-n: n个输入值至少有m个为真, 则输出为真

□ 二层神经网络可以表达所有的布尔函数

✓ 与、或、与非、或非、异或.....

# 感知机学习的不足

□ 感知机学习一定可以收敛吗？

✓ 前提是训练样例必须是线性可分的！！



□ 如果训练样例不是线性可分的，怎么办？

✓ 只能去找一个学习方法，去收敛到目标概念的最佳近似

感知机学习方法只适用在单层网络！

# 思考和讨论

1. 感知机的表达能力
2. 感知机学习法则
3. 线性可分和非线性可分
4. 感知机收敛定理

谢谢！